

자연어처리 종합설계 최종 과제

Universal Career-Path Navigator

자소서·CV 텍스트 기반 직무 도메인 추정 & 직무·연구실 추천 NLP 시스템

PROJECT TEAM

이준구 (팀장) | 손인선 | 윤재웅

도입: 취업·진학 준비생의 두 가지 현실 고민

😞 현실 고민 01

"내가 진짜 어울리는 직무·분야가 어딜까?"

스스로 나의 강점이나 경험을 객관적으로 정량화하기 어렵다 보니, 정작 어떤 방향으로 준비해야 할지 막막해하는 경우가 많습니다.

⌚ 현실 고민 02

"이 아까운 경험을 어디에 써먹어야 할까?"

수백 개의 직무 기술서나 복잡한 대학원 연구실 목록을 매번 수동으로 뒤져봐야 합니다. 시간 낭비와 정보 탐색에 드는 비용이 생각보다 너무 큼니다.

NLP 정량 분석

✂ 자소서 기반 맞춤 안내 시스템

단순히 어휘 매칭에만 그치지 않고, 작성한 자소서의 비정형 텍스트를 인공지능이 맥락까지 읽어내어 가장 알맞은 진로를 정확하게 짚어줍니다.

- ✓ 의미론적 맥락 파악을 통한 최적의 도메인 분석
- ✓ 판단을 내리게 된 구체적인 근거 키워드 추적
- ✓ 학과 내 관련 연구실 및 맞춤형 직무 연동 추천

도입: 활용 시나리오 & 16개 직무 도메인

범용(General Purpose) 분류 체계

어느 한 직군에 치우치지 않고 누구나 쓸 수 있도록 만들었습니다. 국가직무능력표준(NCS)과 실제 채용 공고들의 성격을 고루 조화시켜서 **총 16개의 대표적인 핵심 도메인**을 꼼꼼하게 정리하고 매핑했습니다.

합 취업 및 이력서 검토

작성한 자소서가 내가 가고자 하는 직무 어휘 맥락에 잘 부합하는지 실시간 분석

학과 및 랩실 매칭

연구 계획이나 보유 경험 역량을 근거로 학과 내 교수진 연구실 맞춤 추천

시스템이 탐색 가능한 16개 핵심 산업군



공학·개발



데이터·AI



기획·PM



연구·학술



관리·HR



행정·공공



경제·금융



경영·컨설팅



간호·보건



자연과학



인문·사회



예술·디자인



제조·생산



에너지·발전




항공·우주



미디어 콘텐츠

인문계열부터 첨단 공학까지 아우르는 촘촘한 직무 사전을 배경에 구축해 두었습니다.

방법론: 시스템이 작동하는 유기적인 일련의 파이프라인



i 사용자가 자소서를 드롭하는 시점부터 최종 마인드맵 추천 리포트가 완성되기까지, 브라우저 백그라운드에서 실시간으로 끊임 없이 유기적인 처리가 진행됩니다.

알고리즘: 규칙 기반에서 의미론적 분석까지, 점진적 고도화

실험 방법론	핵심 원리	단독 성능	장점 및 극복한 한계
① 키워드 사전 (Baseline)	도메인별 특화 용어 사전 600여 개 구축	86.9%	전문 도구나 직무 기술 어 휘를 가장 빠르고 정확하 게 찾아냅니다.
② BoN (Bag of N-grams)	한글 자모 2~3-gram 통계 벡터 유사도 계 산	(Hybrid 활용)	단순 오타나 사소한 유사 철자 변형에도 유연하게 대처합니다.
③ SBERT 코사 인 유사도	Multi-MiniLM 기반 384차원 시맨틱 임베 딩	78.6%	글쓰이의 궁극적인 문맥 의도와 유연한 표현을 잘 잡아냅니다.

⚠ SBERT 단독 성능이 더 낮았던 원인 분석

단순 코사인 방식보다 더 고차원적인 **SBERT 모델의 정확도가 오히려 78.6%로 낮게 기록된 점**을 유심히 발견했습니다.

"SBERT는 문장의 전반적인 어조나 서사 맥락을 짚는 데는 뛰어날 수 있지만, 정작 우리 도메인에서 중요하게 다뤄지는 핵심 전문 단어들의 가중치를 무뎌지게 만드는 현상이 발견되었습니다. 이 때문에 의미론적 유사도 점수만으로는 키워드 매칭보다 단독 성능이 떨어지는 한계가 생깁니다. 그래서 이 둘의 장점을 융합하는 복합 설계로 선회하게 되었습니다."

알고리즘: Hybrid 결합 및 가중치 민감도 분석

최종 결합 정확도: 90.5%

단어의 명확성과 문맥 이해의 완벽한 조화

키워드가 짚어내는 명확한 어휘 특성과 SBERT의 맥락 파악력을 함께 조합하여 최적의 결정 수식을 완성했습니다.

$$\text{Score} = \text{Keyword} \times 0.45 + \text{SBERT} \times 0.55$$

최적 결합 결과, **종합 분류 정확도 90.5%**를 확보했습니다. 이는 단독 모델 최고 점수였던 키워드 성능(86.9%)보다 **+3.6%p** 수직 향상된 값으로 두 방식의 상호 보완성이 훌륭히 입증되었습니다.

Keyword Weight 변화에 따른 가중치 민감도 분석



가중치 검증 결과, 0.3에서 0.9 사이의 넓은 지대에서 90.5%의 강력한 고원(Plateau)을 유지했습니다. 특정 지점에 우연히 과적합된 결과가 아닌 구조 자체가 매우 강건하다는 증거입니다.

알고리즘: 학습 분류 헤드 탑재 및 실험적 고도화

3단계 검증을 통한 과적합 해소 과정

고정된 SBERT 임베딩 공간 위에 직접 가벼운 선형 분류 레이어를 연결했습니다. 소규모 데이터에서 마주친 심각한 과적합 문제를 아래 검증 파이프라인으로 풀어 내어 **LOOCV 79.8%**를 달성했습니다.



가벼운 온디바이스(On-device) 최적화 설계: 정교하게 정형화한 로지스틱 회귀 모델은 예측 연산 부하가 극도로 낮습니다. 복잡한 클라우드 서버망을 거치지 않아도 사용자의 프론트 브라우저 단에서 즉시 가볍고 빠르게 결과를 제공합니다.

데이터 기근(Low-Resource) 상황의 모델별 강건성 비교

L2 규제 탑재 로지스틱 회귀 (선형 분류헤드) **79.8%**



다층 인공신경망 MLP (비선형 학습헤드) **67.9%**



공학적 실험 교훈: 학습 데이터가 클래스당 5개 남짓인 열악한 환경에서는 신경망 레이어(MLP)가 높은 표현력 때문에 아주 쉽게 과적합(Overfitting)에 무너 집니다. 이럴 때일수록 엄격한 규제를 준 선형 알고리즘이 훨씬 우월하게 버텨냅니다.

데이터: 엄밀한 성능 측정을 위한 데이터셋 구성

평가 데이터셋 소스 및 난이도별 구성 비율



- Synthetic (정형 분류문장) - 61개
- Lexical Gap (어휘 제약적 의미 판단) - 11개
- Stress / Neg (도메인 혼합/난해) - 12개

단순히 기계가 풀기 쉬운 정형 자소서 문장만 준비하지 않았습니다. 핵심 키워드를 제거하고 의미로만 맞혀야 하는 극한의 문장(Lexical Gap), 여러 직무가 복잡하게 섞여 헷갈리는 문항(Stress Test)을 일부러 주입해 엄중한 평가 구조를 구축했습니다.

데이터 구분	실제 수량	보유 세부 가공 사항
평가용 데이터셋	총 84개	16개 분류 분야별로 정밀하게 5개씩 균등 분포 설계
실제 자소서 홀드아웃	총 30개	원본 실제 기업 합격 자소서 PDF (평균 2,400자 기준)
데이터 단일 출처화		<code>evaluationDataset.js</code> 를 원천 소스로 영구 고정 → 빌드 돌릴 때 빌드 스크립트가 JSON을 자동 갱신해 수치 오류 방지

지속적인 노이즈 정제 작업: 1) 기계적인 문장 단위 완벽 분리 전처리 적용, 2) 비정형 문서 텍스트 파편 요소 필터링, 3) 자소서에서 반복해서 나타나는 28가지 상투적 문장 양식을 배제하는 전처리 엔진을 직접 설계했습니다.

평가: 7가지 성능 교차 검증 통계 결과

비교 대상 실험 알고리즘군	Accuracy (정확도)	95% Bootstrap CI (신뢰한계)	Macro F1-Score	도메인 커버리지
1. Keyword-only (Baseline)	86.9%	[79.8%, 94.0%]	87.4%	89.3%
2. BoN Hybrid (통계 자모 결합형)	89.3%	[82.1%, 95.2%]	89.4%	91.7%
3. SBERT-only (의미론적 단독)	78.6%	[69.0%, 86.9%]	79.5%	89.3%
📌 4. SBERT Hybrid (최종 채택 엔진)	90.5%	[83.3%, 96.4%]	90.7%	91.7%
5. SBERT Hybrid + 임계값(Threshold)	90.5%	[84.5%, 96.4%]	90.7%	91.7%
6. Learned Head (LOOCV)	79.8%	[71.4%, 88.1%]	78.6%	100.0%
7. Learned Head Hybrid (학습 결합 참고용)	92.9%	[86.9%, 97.6%]	89.7%	100.0%



학술적인 엄격성 검증: 단순히 획일적인 수치만 보고하지 않았습니다. 통계적 신뢰성을 증명하기 위해 무작위 복원 리샘플링을 2,000회 수행하여 95% Bootstrap 신뢰한계를 과학적으로 도출했습니다.



SBERT Hybrid 분류기를 고집한 이유: 정확도 90.5%와 더불어 F1-Score 역시 90.7%라는 최고의 균형을 달성했습니다. 이는 현실적인 구직 데이터 기근 상태에서 가장 강인하고 정답률이 고른 조합입니다.

정직성: 일반화 갭(Generalization Gap) 및 정제되지 않은 데이터 통계 분석

→ 현실 실데이터 검증 결과

일반화 오차: -18.1%p

가공된 가상의 단문 데이터셋에서 90.5%를 달리던 분류기가, 실제 다듬어지지 않은 원본 합격 자소서 PDF 30개 검증 시에는 **72.4%** 수준으로 내려가는 오차가 존재합니다. 저희 팀은 이 현실의 격차(일반화 갭)를 숨기지 않고 정직하게 밝힙니다.

정형 가상 평가셋 분류 정확도 (Synthetic Test) 90.5%



진짜 낱것의 실제 자소서 정확도 (Real Holdout) 72.4%



가장 가치 있는 실험 결과 (F1-Score 기준)

실제 복잡한 현실 자소서를 풀게 했을 때, SBERT Hybrid 분류기(86.4%)는 키워드 단독 분류기(79.0%)보다 뚜렷하게 우수했습니다. 낱것의 문장일수록 문맥 의미 분석이 정답을 짚어내는데 주효하다는 것을 보여줍니다.

정제하지 않은 현실 데이터 실험

노이즈에 의한 성능하락

과대평가 보정 선언: 예전 보고서의 97.1% 성능 지표는 소수 68개 데이터 위에서 기록된 일종의 과대평가였습니다. 저희 팀은 평가셋을 84개로 대폭 키우고, 꼬아놓은 정교한 오답 유도 지문들을 가혹하게 주입해 수치를 90.5%로 투명하게 바로잡았습니다.

오염원 주입 실험 사례


PDF를 분류 학습셋에 추가 이식한 결과, LOOCV 예측 정확도가 79.8%에서 77.4%로 오히려 -2.4%p 급감하였습니다.

데이터는 양보다 질이 생명이라는 진실

지원서 본문에 섞여 있던 '인재상', '회사 입사 지침', '정형화된 가이드 문장'이 유의미한 직무 판별을 크게 흐리는 '노이즈(잡음)'로 작용했기 때문입니다. 무작정 데이터의 양만 늘린다고 인공지능이 똑똑해지지 않는다는 교훈을 정량적으로 증명해 냈습니다.

분석: 학습 볼륨에 따른 성능 차이 분석 (Learning Curve)

🔗 학습 훈련 데이터 크기 증가에 따른 선형 학습 헤드의 정확도 향상 추이



📈 데이터 수집 볼륨과 모델 학습 성능의 상관관계

학습 데이터를 N=14에서 N=56까지 단계별로 차례대로 투입하면서 선형 분류 헤드의 능력을 측정했습니다. 결과 그래프를 보시면 성장의 꺾임이나 정체기(Plateau)를 전혀 보이지 않고 41.7%에서 76.2%까지 아주 곧게 직선으로 우상향하고 있는 구조를 눈으로 확인할 수 있습니다.

성능 한계의 원인은 알고리즘의 결함이 아니라, 단순한 학습 데이터 양의 부족 때문이라는 점을 확인했습니다. 추후 깨끗하고 레이블이 완벽히 정제된 고품질 데이터를 더 많이 확보해 가르친다면, 최종 baseline 수치를 충분히 돌파할 강력한 미래 잠재력을 품고 있습니다.

라이브 데모: 대시보드 실시간 분석 시연



01. 자소서 업로드

보유 자소서 PDF를 창에 올려 놓으면, 클라이언트 pdfjs 분석기가 실시간으로 텍스트를 인출합니다.



02. 적합 분포 시각화

SBERT와 가중 키워드 결합을 통해 도메인 분포 적합도를 깔끔한 방사형 레이더로 바로 그려냅니다.



03. Audit 근거 확인

인공지능이 왜 이런 결정을 지었는지 실시간으로 중요 단어와 기여도를 색인하여 투명하게 추적합니다.



04. 직로-연구실 마인드맵

결과 분석이 끝나면 어울리는 직무와 연결되어 있는 학과 내 교수진 랩실을 마인드맵으로 제시합니다.

마무리: 현재의 한계와 향후 발전 과제

TECHNICAL BOTTLENECKS

⚠ 우리가 마주한 극복 과제

- ✕ **모델 네트워크 로딩 지연:** 약 40MB에 가까운 온디바이스 시맨틱 모듈을 브라우저에 최초 다운로드할 때 초기 네트워크 로딩 병목이 존재합니다.
- ✕ **어휘의 다중 중의성 문제:** 다중 분야에 걸쳐 애매하게 겹쳐서 사용되는 문맥들을 완벽하고 날카롭게 분리하는 정밀도가 조금 더 보완되어야 합니다.
- ✕ **가상 데이터와 현실 데이터의 오차:** 가상 정형 평가셋(90.5%) 대비, 날것의 긴 호흡을 가진 실제 자소서 데이터셋(72.4%) 간에 여전히 존재하는 약 18%p 폭의 일반화 오차 극복이 필수적입니다.

FUTURE ROADMAP

🚀 향후 발전 과제

- ★ **한국어 특화 ko-SBERT 모델 이식:** 기존 다국어 SBERT 모듈을 10MB 크기 내외의 가볍고 강인한 한국어 특화 ko-SBERT 혹은 bge-m3-ko 전용 엔진으로 포팅하겠습니다.
- ★ **실시간 구인구직 API 실시간 연계:** 사전에 설계한 학과 내에 갇힌 정형 마인드맵을 넘어, 잡코리아나 원티드 같은 실제 채용 사이트 API를 따와 실시간 활성 채용공고와 연결해 주겠습니다.
- ★ **SBERT 임베딩 파인튜닝 가동:** 단순히 pre-trained 임베딩을 가져다 쓰는 차원을 넘어, 직무 판단 능력을 애초에 극대화할 수 있게 임베딩 공간 자체를 우리의 16대 직무 기반에 맞춰 Fine-tuning 시키겠습니다.

팀 협업: 역할 분담 및 정량적 성과 관리

팀원 및 주역 역할	담당 세부 과업 영역	정량적 최종 산출 성과물
이준구 (팀장)	NLP 복합 파이프라인 설계 및 React 프론트 가시화 구현	4개 병렬 분류 알고리즘 구축, SBERT Hybrid 결합 공식 설계, 웹 마인드맵 차트 개발 완수
손인선	현실 합격 자소서 데이터 수집 및 NCS 도메인 라벨링 과업	평가용 균형 데이터셋 84개 세밀 확보, 실제 검증용 원형 PDF 30개 수급 및 텍스트 파싱 처리 완수
윤재웅	평가 및 실험 정밀 설계	7-way ablation, LOOCV, CI, 학습곡선



Git 커밋 기반 이력 추적: 분리 브랜치 기법을 엄격히 적용하고 머지 충돌을 지혜롭게 차단하여 배포 결함률 0%를 유지하며 끝마쳤습니다.



재현 가능한 과학적인 검증: 단일 소스 원칙(`evaluationDataset.js`)에 기반해 가동 수치 오류를 완벽하게 차단했습니다.

UNIVERSAL CAREER-PATH NAVIGATOR

감사합니다
